

### **计连架构 成长之路**

### SACC 第十届中国系统架构师大会

SYSTEM ARCHITECT CONFERENCE CHINA 2018

2018年10月17-10月21日 北京海淀永泰福朋喜来登酒店







## 品友大数据分析平台的架构和演化

王晓鹏











## 议程

- 大数据分析的步骤
- 品友大数据分析平台的架构
- 投放分析平台的演进
- 数据管理分析平台的演进
- 工具的探索与实践
- 总结









## 大数据分析步骤













### 品友应用大数据分析的产品



投放分析平台

品友的广告投放平台 用户为广告投放运营



企业数据管理平台

DMP,SaaS,In-House,Hybrid 用户为企业市场,IT,数据分析



目的不同



使用场景不同



数据不同



面向用户不同











### 品友投放数据及其分析需求

基础一方数据 (用户资料,用户标签):

15G/日\*365+40G \*12月 = 5T/年 考虑20%的业务增长率后为: 6T/年 广告行为数据: 250T/年

考虑20%的业务增长率后为:

300T/年

分析数据: 600G/日

考虑20%的业务增长率后为: 272T/年

#### 数据存储的建议

- □ 鉴于用户换机周期为1.5年,我们建议广告行为数据存储1.5年;
- □ 一方标签数据、分析数据、报表数 据永久存储
- □ 建议分配存储: XX (与研发确认)

#### 关键性指标

- □ 多维分析查询速度:不高于10秒 (不含用户访问查询页面的时间);
- □ 人群预估响应时间: 秒级;
- □ 人群生成响应时间:与人群规模有 关;
- □ 并发查询数目: 1000请求/秒;



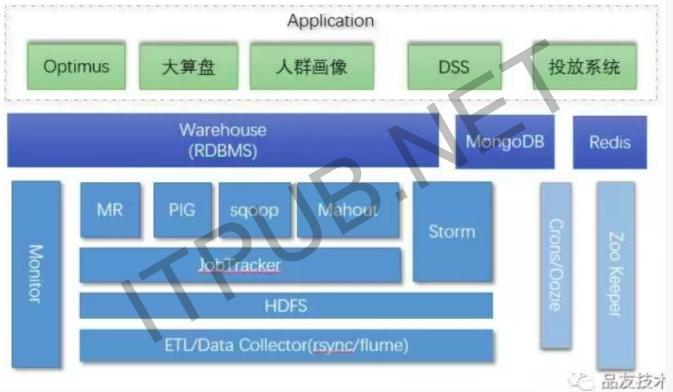
十年架构 成长之路







### 第一代大数据平台(2013-2014)



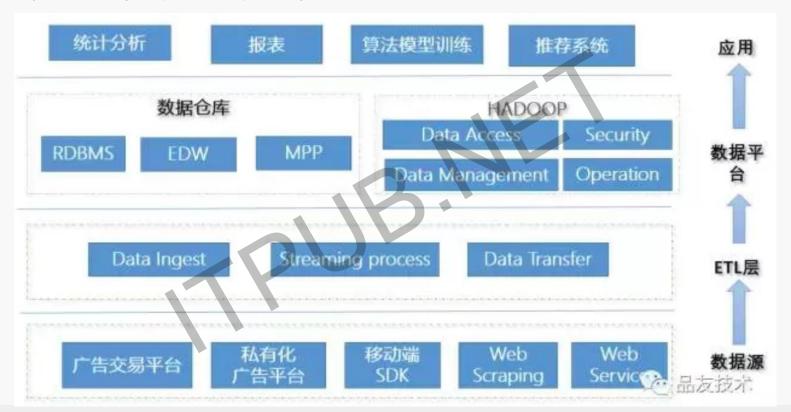








### 第二代大数据平台(2015-2016)

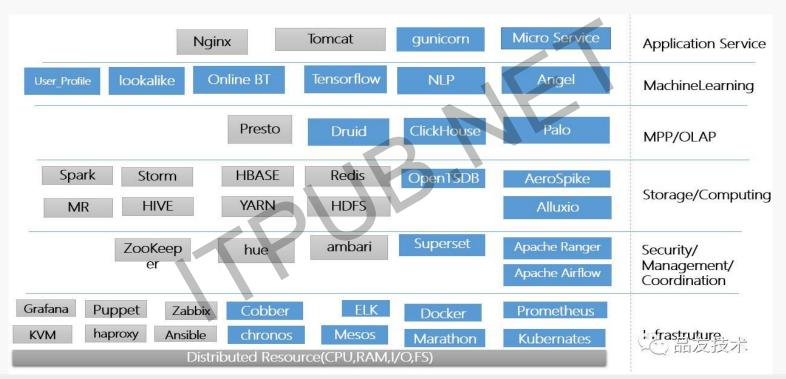








### 第三代大数据平台(2016-现在)













### DMP的数据及分析需求

数据来源 ●曝光 投放数据 ●点击 •访客 ●微信 社交活动 ●微博 CRM 商业 • ERP •WIFI 其它 •IoT • 离线数据

用户角色及需求

П

- •数据资产
- •数据质量

业务运营

- •报表洞察
- •趋势分析

数据科学家

- •灵活的数据操作
- •数据建模
- •预测分析











## 没有银弹(No Silver Bullet)



#### 投放数据

来自广告投放及网站访问事件



#### 第一方数据

属于客户第一方的多种数据





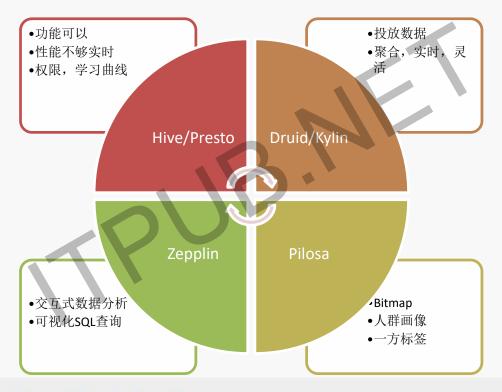
### 十年架构 成长之路







### DMP数据分析的全面开花











### **DRUID**

- 高性能的,分布式列存储的MOLAP框架
- 特点
  - 亚秒级查询
  - 实时数据注入
  - 可扩展的PB级存储
  - 支持多种数据源: hadoop, spark, kafka, storm和samza等
- 缺点
  - 只有聚合结果,没有明细



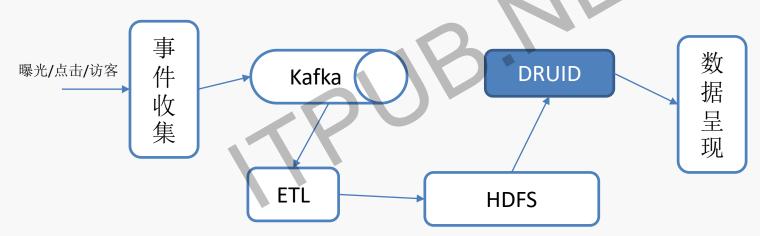






## Druid在品友的实践

- 使用场景:广告实时统计分析
- 数据:投放数据,20亿/天











# Zepplin,数据分析师的心头好

- Apache Zepplin是可视化框架
- 应用于交互式数据分析, 七牛云,
  - 支持多种语言,默认是scala(背后是<u>Spark</u> shell), SparkSQL, Markdown 和 Shel
- 功能
  - 数据可视化
  - 用SQL来进行可视化查询

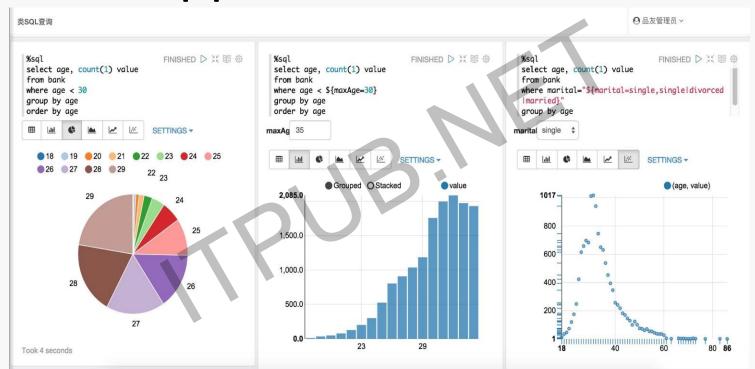








# Zepplin在品友的实践



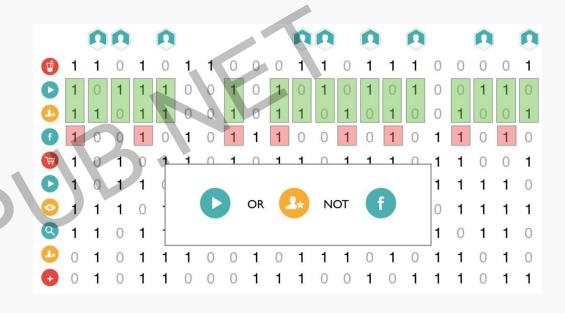






## Pilosa在品友的实践

- Bitmap对海量用户进行 标签
  - 0/1来代表有某标签
- 人群画像速度提升
- 人群查询方便
- 易于扩展











### Palo vs ClickHouse

	Palo	ClickHouse
Count	89.7秒	0.23秒
Group By(单线程)	0.14秒	0.47秒
Group By(多线程)	略优	-
实时导入	不支持	支持
写入速度	2.5万行/秒	14.2万行/秒
存储空间	8.7G	9.5G









## 选择。。。选择。。。

- ClickHouse vs Palo
- Druid vs Kylin
- GreenPalm vs Elastic Search







# 自己动手, 丰衣足食

- 数据Console
- 机器学习平台
- 加速数据分析 Alluxio
- Knime









# 品友数据分析平台总结

- 根据数据量,使用者角色设计设计分析平台很重要
- 对工具的选择来说,没有银弹
- 走工具+自我开发的道路









