

计连架构 成长之路

SACC 第十届中国系统架构师大会

SYSTEM ARCHITECT CONFERENCE CHINA 2018

2018年10月17-10月21日 北京海淀永泰福朋喜来登酒店







腾讯GaiaStack容器产品私有云场景实践













自我介绍

陈纯,腾讯TEG数据平台部高级工程师

- Docker Libnetwork项目maintainer
- 《循序渐进学docker》作者之一
- 对容器生态的Kubernetes, Docker, runc, Libnetwork, Flannel等开源项目都有大量的源代码贡献









GaiaStack介绍

GaiaStack是腾讯基于Kubernetes打造的企业级容器云平台。

GaiaStack作为数据中心操作系统,可以调度CPU或GPU等海量计算资源,运行所有计算框架,监控任务执行结果,让数据中心的所有资源被合理使用,协同完成各类应用场景的计算。



GaiaStack

提供了从构建至交付到运行的一整套的解决方案



容器服务



持续集成



镜像仓库



咨酒编排



私有集群



部署与管理




十年架构 成长之路







GaiaStack功能及应用场景









社区版Kubernetes私有云场景挑战

- 资源纬度仅支持CPU、Memory、ephemeral-storage(1.12 beta),网络出入带宽和磁盘IO如何管理?
 - http://2017.qconbeijing.com/presentation/512
- Deployment、Statefulsets、Job、CronJob应用类型真的好用吗?
- Flannel、calico、weave容器网络选用哪个?负载均衡用什么?
- 云硬盘用哪个?
- 升级版本不兼容?
- 日志,监控,告警问题










Kubernetes扩展接口












GaiaStack Kubernetes













TAPP应用类型


利用Kubernetes CRD功能自研TApp应用类型,与Kubernetes Statefulset应用类型相同点:

- Pod具有唯一自增ID
- 绑定单独云盘,迁移时数据盘跟随迁移

优势:

- · 支持指定若干实例多次进行删除、停止、重启、 原地灰度升级、回退Pod等操作
- 单个TAPP应用的Pod支持N个版本
- 不只是修改镜像版本,甚至可以多加一个容器

```
type TAppSpec struct {
    Template corev1.PodTemplateSpec //默认Pod模板
    TemplatePool map[string]corev1.PodTemplateSpec
    Statuses map[string]InstanceStatus
```











Galaxy-CNI网络插件

因为各种不同场景的需要,自研网络项目Galaxy

- 同时提供Underlay + Overlay方案
- 普适性,多种网络适应不同场景
- 性能领先

选择应用适合的网络方案

- 不同的应用可以选择不同的网络模式
- 同一主机的不同容器可以选择不同的网络模式








十年架构 放长之路

Pod Underlay IP漂移













Overlay方案性能





GaiaStack提供Overlay方案是IPIP + Host Gateway 混合方案,性能仅次于calico3层方案短链接 Vxlan比HOST**差33%**, IPIP比HOST**差23%**, Gateway比HOST只差**6%** 方案被社区合并 https://github.com/coreos/flannel/pull/842












Underlay方案性能



Bridge比Host仅**差6**%













Underlay网络案例



Bridge/SRIOV Underlay网络

将容器的IP和端口直接绑定到TGW 将TGW的Tunnel网卡创建到容器中














CPU使用<mark>降低1/3</mark>





包量+6%



SACC 第十届中国系统架构师大会

上周期 入包量(个/秒) 最新值:7,815 平均值:12,665 峰值:29,408(08-16 19:50)




上周期 出包量(个/秒) 最新值:10,567 平均值:16,662 峰值:37,264





实现kubernetes网络策略













BGP协议的使用

Calico/contiv提供了BGP L3 network的实现, 给容器提供一个完全无封包的网络

• 要求交换机开启BGP功能,实质是一种基于 BGP协议的数据中心网络架构。

BGP对于容器网络的价值:

- 无封包的网络方案
- 解决不完全连通网络的容器跨主机访问的问题。相比Weave用gossip协议实现P2P网络,标准路由协议的优势: AS Path防环路;
 Route Reflector/Route Server解决P2P的性能问题

相互隔离网络

Galaxy借助GoBGP实现BGP协议的支持












GPUManager设备插件

- 自研Kube-scheduler调度器插件 + Device Plugin GPU Manager
- 异构集群的精细化管理
 - 管理不同型号的GPU(如:M40、P40等)组成的集群限定不同业务可以使用的卡种类和数量
 - 保证业务能够使到预期的GPU资源 (GPU卡数,GPU型号)
- 调度分配优化
 - Drain node调度解决资源碎片问题
 - 多卡需求按GPU架构优先分配距离较近的卡












GPU虚拟化

业内首创容器场景的GPU虚拟化技术

- 多个程序共享同一张GPU卡,提高资源利用率
- 支持GPU卡, GPU内存的虚拟 tencent.com/vcuda-core=0-100、 tencent.com/vcuda-memory=0-100
- GPU卡和内存资源申请通过Manager进行限速,用户程序的数据流不经过Manager
- 对用户程序零入侵
- 基于kubernetes device plugin实现,对 kubernetes、kernel无入侵











```
-]# curl -s localhost:1234/graph|jq -r .graph
---SOC (aval: 6, pids: [31921 32267], usedMemory: 32280412160, totalMemory: 205292306432, allocatableCores: 0, allocat
 PIX (aval: 0, pids: [31921 32267], usedMemory: 32280412160, totalMemory: 51323076608, allocatableCores: 0,
   | ---GPU0 (pids: [31921], usedMemory: 7781613568, totalMemory: 25661538304, allocatableCores: 50, allocatable
      |----GPU1 (pids: [32267], usedMemory: 24498798592, totalMemory: 25661538384, allocatableCores: 0, allocatable
      |----GPUZ (pids: [], usedMemory: 0, totalMemory: 25661538304, allocatableCores: 100, allocatableMemory
       |---GPU3 (pids: [], usedMemory: 0, totalMemory: 25661538304, allocatableCores: 100, allocatableMemory: 256
 |---GPU5 (pids: [], usedMemory: 0, totalMemory: 25661538304, allocatableCores: 100, allocatableMemory: 256
      ---PIX (aval: 2, pids: [], usedMemory: 0, totalMemory: 51323076608, allocatableCores: 0, allocatableMemory: 0
      |---GPU6 (pids: [], usedMemory: 0, totalMemory: 25661538304, allocatableCores: 100, allocatableMem
       |---GPU7 (pids: [], usedMemory: 0, totalMemory: 25661538304, allocatableCores: 100, allocatableMemory: 256
```

vcuda-1容器器申请了了50%的利用率, 7680MB,运行行行在0号GPU, vcuda-2容器器独占卡, 运行在1号GPU; vcuda-1的训练速率 是平均43.8/s, vcuda-2的训练速度是 平均86.6/s

vcuda-1容器器 申请了了30%的利利用 用率,7680MB,运行在0号GPU, vcuda-2容器器申请了 60%利用率,12800MB,运行在0号 GPU; vcuda-1的的训练速率是平均 25.22/s , vcuda-2的训练速度是平均 54.7/s

```
--50C (aval: 7, pids: [25398 25477], usedHemory: 20663500800, totalHemory: 205292306432, allocatableCores: 0, alloca
---PIX (aval: 2, pids: [], usedMemory: 0, totalMemory: 51323076608, allocatableCores: 0, allocatableMemory: 0
     |---GPU2 (pids: [], usedMemory: 0, totalMemory: 25661538304, allocatableCores: 100, allocatableMemory: 256
---PIX (aval: 2, pids: [], usedHemory: 0, totalHemory: 51323076608, allocatableCores: 0, allocatableHemory: 0
```













磁盘空间管理

GaiaStack修改了调度器和Kubelet以支持本地磁盘管理,相比Kubernetes emptyDir优势:

- 支持多块盘
- 支持弹性管理,允许临时超出
 - 单个Pod超出limit大小后若机器磁盘仍有余量可以暂时使用

目前耦合在Kubernetes代码中,后续计划用scheduler plugin和CSI接口进行优化











云盘管理

- 支持CephRBD、CephFS,腾讯公有云CBS、CFS等
- 外部controller支持CephFS dynamic provisioning
- Kubelet支持Volume在线扩缩容,
 https://github.com/kubernetes/kubernetes/pull/62
 460

TCP nodelay & delay 4k randread对比测试 3000 40 2500 2000 25 15 1000 10 500 5 0 16 iops tcp nodelay iops tcp delay -O-latency tcp nodelay -O-latency tcp delay


一名Ceph官方组织成员

- · 提升mds对大量文件的目录处理速度6~10倍
- · 提高了mds主备切换的速度
- · Cephfs内核模块稳定性改进, bug fix
- 支持quota
- 支持Jewel, 支持keyring挂载权限



| 「他化前・IOPS | 世化的 IOPS | 一● 性化前・clat(msec) | ー● 性化前・clat(msec)


P2P Docker registry



- P2P Registry:镜像仓库,种子生成,种子下载,文件初始提供者
- · Agent: Docker透明代理,下载任务的主要功能组件
- BT Tracker: P2P下载资源查询定位组件

主要设计思想:

- · 在镜像下载过程中,引入BT协议
- 在Blob上传时,对Blob生成种子
- 每层分别做种
- 在下载镜像的Blob时, 先下载种子, 再通过种子文件下载数据















P2P Docker registry

- 每层分别做种,下载速度更快
- 优化流量调度算法,节省registry流量
- 代理方式,对Docker Daemon零入侵

Docker、Docket、Gaiastack P2P Agent下载镜像对比



Registry与P2P Agent流量占比对比













热升级问题

1.4升级1.9版本

- Pod Hash发生变化
- Container名称发生变化,点分隔改为了下划线分隔
- 容器标签发生变化
 - pause容器的标签io.kubernetes.container.name=POD改为io.kubernetes.docker.type=podsandbox
 - io.kubernetes.container.restartCount改为 annotation.io.kubernetes.container.restartCoun
- Cgroup目录结构发生变化,新增Pod层级









